Pyrite Phase 2: 疎結合メモリ階層による 100B 超 MoE 言語モデルのコンシューマ PC・ユニファイドメモリ実行技術

中津川 昌弘
株式会社 n.p.minerva (tip.co.jp)　AntenneFrance
huggingface.co/masahiroid　ORCID: 0009-0000-3224-0103

プレプリント — DOI: 10.5281/zenodo.23811995

概要

Mixtral-8x22B（1,410 億パラメータ）や DeepSeek-Coder-V2-Lite（15.7B パラメータ、64 エキスパート）などの Mixture-of-Experts（MoE）モデルは極めて優れた知能を有するが、その巨大なサイズ（70GB〜280GB）のため、ローカル実行には 128GB〜192GB 以上のメモリを積んだ高額なワークステーションや GPU クラスタが不可欠であった。本稿では、モデルの静的な常駐ワーキングセットと動的に選ばれるルーテッド・エキスパートを完全分離する実行アーキテクチャ「Pyrite Phase 2 (MoE-Stream)」を提案する。Attention 機構、LayerNorm、ルーターゲート、トークン埋め込み層のみをユニファイドメモリ（RAM）に常駐させ、アクティブな Top-K エキスパートのみを NVMe SSD からマイクロ秒単位（68 μs）のゼロコピー・リニアバイトスライスとインメモリ LRU キャッシュによりオンデマンドで取得することで、一般的な 16GB Mac 上での極限的な省メモリ実行を実現した。Apple M2 Pro（16GB RAM）の実機評価において、DeepSeek-Coder-V2-Lite をわずか **1.55 GB〜2.01 GB の RAM 消費量、2.83 tok/s** の速度で動作させた（83%〜93% のメモリ削減）。さらに、1,410 億パラメータの超巨大モデル **Mixtral-8x22B の全 56 層フォワードパスをわずか 2.84 GB〜3.61 GB の実効 RAM 消費量で完走**させることに成功した。これにより、16GB の市販ノート PC であっても、12GB 以上の RAM 空き領域を残して 100B 超の巨大モデルを実行できる道が拓かれた。

1　はじめに

現代の大規模言語モデル（LLM）の推論実行は、計算速度以上に「メモリ容量」と「メモリ帯域」によって強く制約されている。MoE（Mixture-of-Experts）アーキテクチャは、各トークンで全体のわずかなパラメータ（エキスパート）しか使わないため、計算量自体はパラメータ数に比べて極めて小さい。しかし、従来の推論基盤（llama.cpp や Ollama 等）は「全重みを一括して RAM 上に展開する」前提であったため、141B の Mixtral-8x22B などを動かすには数百万円規模のハードウェアが必要とされていた。

二次記憶（SSD）から層ごとにロードする AirLLM 等の手法は、Dense モデル（Llama-3-70B 等）において毎トークンごとに 70GB 全データを PCIe 経由で転送せねばならず、1 トークン生成に約 14 秒を要し実用性に乏しかった。本研究では、MoE 固有の「空間的スパース性（疎結合性）」に着目し、非 MoE 基幹部（約 1.5GB〜2.3GB）のみを RAM に常駐させ、Top-K エキスパートのみを NVMe からダイレクトにゼロコピー取得・Metal GPU 上で完全ベクトル集計する「MoE-Stream」を開発・実機検証した。

2　アーキテクチャと数理モデル

2.1　メモリ階層の直交分解

全パラメータ集合 Θ を、常駐集合 Θ_{resident} と動的ルーティング集合 Θ_{routed} に直交分解する：

$$\Theta = \Theta_{\text{resident}} \cup \Theta_{\text{routed}} \tag{1}$$

■常駐パラメータ (Θ_{resident}): トークンを問わず毎ステップ必ず使用される構成要素群：

- 埋め込み層 $\mathbf{W}_{\text{embed}}$ および LM Head $\mathbf{W}_{\text{head}}$
- Self-Attention（Q, K, V, O 射影行列）
- Pre/Post-Attention RMSNorm 重みベクトル
- ルーターゲート行列 $\mathbf{W}_{\text{gate}} \in \mathbb{R}^{E \times D}$
- 共有エキスパート（DeepSeek-V2 の場合）

$\dim(\Theta_{\text{resident}}) \ll \dim(\Theta)$ であるため、141B の Mixtral であってもわずか約 2.3 GB に収まる。

■動的ルーティングパラメータ (Θ_{routed}): 各層 E 個のエキスパート FFN。各トークンに対しルーターが Top-K エキスパート（Mixtral は $K = 2$、DeepSeek は $K = 6$）のみを選出する。safetensors 内の連続配置を利用し、オフセットを直接計算して 68 μs で抽出する。

2.2 Metal GPU 完全ベクトル化集計

複数トークンがバッチ内に存在する場合、個別に Python ループで散布加算するのではなく、Metal GPU 上でアクティブな重みマスク $\mathbf{M}_e$ を用いた単一グラフによる行列加算として実行し、CPU-GPU 同期オーバーヘッドを完全に排除した。

3 実機評価結果

Apple M2 Pro（16GB ユニファイドメモリ、2TB NVMe SSD、macOS 27.2）実機で評価した結果を以下に示す：

表 1 16GB Apple M2 Pro 実機でのメモリ消費と生成速度

モデル	総パラメータ	実機 RAM	削減率	速度
DeepSeek-Coder-V2-Lite	15.7B	**1.55 GB**	87.1%	2.83 tok/s
DeepSeek (Cache 16)	15.7B	**2.01 GB**	83.3%	2.83 tok/s
Mixtral-8x22B (4-bit)	141.0B	**2.84 GB**	96.1%	全 56 層完走
Mixtral (Cache 4)	141.0B	**3.61 GB**	95.1%	全 56 層完走

4 結論と展望

MoE-Stream により、16GB の市販 Mac で 1,410 億パラメータモデルが 3.6GB 以下のメモリで稼働することが実証された。今後は、ビットシャッフルによる可逆ストリーミングや SVD 分解を組み合わせ、離散量子化に依存しないロスレス推論の実現を目指す。