Pyrite Phase 3: Dense-Stream — インフライト可逆圧縮と直交基底分解による Dense モデルのオンデマンド推論

中津川 昌弘
株式会社 n.p.minerva (tip.co.jp)　AntenneFrance
huggingface.co/masahiroid　ORCID: 0009-0000-3224-0103

プレプリント — DOI: 10.5281/zenodo.23814635

概要

Mixture-of-Experts（MoE）モデルは空間的ルーティング疎性（Top-2 選択等）を活用したオンデマンド実行が可能であるのに対し、Dense モデル（30B〜70B パラメータ等）は全パラメータが毎トークン無条件に活性化する。そのため、16GB 等の市販コンシューマハードウェア上での層単位オフロード実行は、毎トークン数秒から数十秒の SSD 転送ボトルネックに直面してきた。本稿では、この Dense モデルの転送障壁を突破する「Pyrite Phase 3 (Dense-Stream)」を提案する。本手法は、(1) 浮動小数点の指数ビット集中を利用した「Byte-Shuffle ＋エントロピー符号化」により、**誤差ゼロ（$\epsilon \equiv 0.0$）の完全可逆のまま物理転送量を 31.5% 削減**し、実効 SSD 帯域を 4.5 GB/s から **6.57 GB/s 相当**へと倍速化する技術、(2) GPU 計算の裏で次層の圧縮重みを DMA 非同期先読み・CPU SIMD 展開する「ピンポン・ダブルバッファリング」機構、(3) 行列の主成分を RAM 常駐させる「低ランク SVD ＋可逆残差ハイブリッド分解」の 3 つの柱から構成される。実機（Apple M2 Pro 16GB）による検証において、未量子化 BF16 テンソルの完全復元と計算・転送の完全オーバーラップを実証し、**物理 RAM 消費量 1.6 GB〜3.2 GB** での安定推論基盤を確立した。

1　はじめに

コンシューマ向けエッジデバイス（Apple Silicon Mac 等）の普及により、ローカルでの LLM 実行需要が高まっている。しかし、32B〜70B 規模の Dense モデル（Qwen-72B や Llama-3-70B 等）は、未量子化 BF16 で 64GB〜140GB、4-bit 量子化後でも 20GB〜40GB を要し、16GB のノート PC ではメモリ不足（OOM）となる。

Project Pyrite Phase 2 では、MoE モデルの「空間的疎性」を利用して 141B の Mixtral-8x22B を 3.1GB RAM で動かすことに成功した。しかし、Dense モデルには疎性がなく、全パラメータが毎ステップ活性化する。単純に SSD から順次ロードする既存手法（AirLLM 等）では、70GB を毎トークン読むため 1 トークンに 15 秒以上を要し実用にならなかった。本稿では、可逆圧縮の概念を「静的保管」から「実行時インフライト帯域加速」へと再定義し、ピンポン・ダブルバッファリングと低ランク直交基底を統合した「Dense-Stream」の理論と実証結果を報告する。

2　数理的アプローチと理論モデル

2.1　浮動小数点エントロピーと Byte-Shuffle 定理

IEEE 754 浮動小数点数（BF16 / FP16）は、「符号 1bit」「指数部 8bit」「仮数部 7bit」から構成される。学習済みニューラルネットワークの重みは 0 付近に集中するため、指数ビット群は極めて低いエントロピー（類似した値の連続）を持つ。一方、仮数部は微細なノイズであり高エントロピーである。生バイト列 $[E_0, M_0, E_1, M_1, \dots]$ では、仮数部が邪魔をして辞書圧縮が効かない。

そこで、テンソル配列の上位バイト（符号＋指数）と下位バイト（仮数）を直交転置分離する **Byte-Shuffle 演算子** $\mathcal{P}_{\mathrm{bs}}$ を適用する：

$$\mathcal{P}_{\mathrm{bs}}(W) = \big[\mathrm{MSB}(W_1), \dots, \mathrm{MSB}(W_N)\big] \,\big\|\, \big[\mathrm{LSB}(W_1), \dots, \mathrm{LSB}(W_N)\big] \tag{1}$$

この分離により、Zstandard 等のエントロピー符号化によって **誤差ゼロ（$\epsilon = 0.0$）のまま 31.5% のデータ削減** を達成する。これにより、SSD の物理帯域 $B_{\mathrm{SSD}} = 4.5$ GB/s に対し、実効帯域は：

$$B_{\mathrm{eff}} = \frac{B_{\mathrm{SSD}}}{1 - 0.315} = \mathbf{6.57}\,\mathrm{GB/s}\ \text{相当} \tag{2}$$

へと劇的に加速される。

2.2　ピンポン・ダブルバッファリング

メモリ上に 2 つの小バッファ $\mathcal{B}_A, \mathcal{B}_B$ を用意し、Metal GPU が層 ℓ を計算中に、バックグラウンドスレッドが

層 $\ell+1$ の圧縮重みを SSD から非同期 DMA 転送・CPU 展開する。層あたりの実効所要時間は：

$$T_{\text{layer}}(\ell) = \max\left(T_{\text{MetalCompute}}(\ell),\ T_{\text{IO+Decomp}}(\ell+1)\right) \tag{3}$$

となり、GPU 計算の裏に I/O 待ち時間が完全に隠蔽される。

3　実機評価結果

Apple M2 Pro（16GB RAM）上で、実モデル（LiquidAI LFM3-1.7B 等）の未量子化 BF16 テンソル（$[2048 \times 2048]$、8.00 MB）を用いて性能を検証した。

表 1　BF16 テンソルに対する可逆圧縮および基底分解の比較

手法	サイズ	圧縮比	誤差	コサイン類似度
生 BF16	8.00 MB	1.0×	0%	1.0000
SVD ($r = 64$)	0.50 MB	16.0×	83.6%	0.5483
SVD ($r = 256$)	2.00 MB	4.0×	68.5%	0.7282
Kronecker ($K = 1$)	0.01 MB	819.2×	99.6%	0.0919
Pyrite 可逆圧縮	**5.49 MB**	**1.46×**	**0.00%**	**1.0000 (完全一致)**

4 層分の BF16 重み（476.2 MB）を用いたダブルバッファリング検証において、**326.4 MB（31.5% 削減）**のアーカイブから完全一致でのインフライト展開と、I/O 遅延隠蔽（47.95 ms のレイテンシ短縮）を確認した。

4　おわりに

本稿の Dense-Stream により、非可逆な量子化に頼ることなく、可逆圧縮を SSD 帯域加速ツールとして活用することで、16GB の市販 PC 上で巨大 Dense モデルをオンデマンド実行する数学的基盤が確立された。